

22/10/2024

Econométrie spatiale Partie 3

M2 ECAP

Muriel Travers
LEMNA, IAE Economie et Management
Université de Nantes



5) Estimation de modèles “spatiaux”

Spatial Lag, Spatial Autoregressive (SAR) : $y = \rho W y + X\beta + \varepsilon$

- La valeur de y dans une unité spatiale peut avoir un impact sur la valeur de y dans une unité spatiale voisine
 ρ : paramètre spatial autorégressif indiquant l'ampleur de l'interaction existant entre les observations de y

Spatial Error (SEM): $y = X\beta + u, u = \lambda W u + \varepsilon$

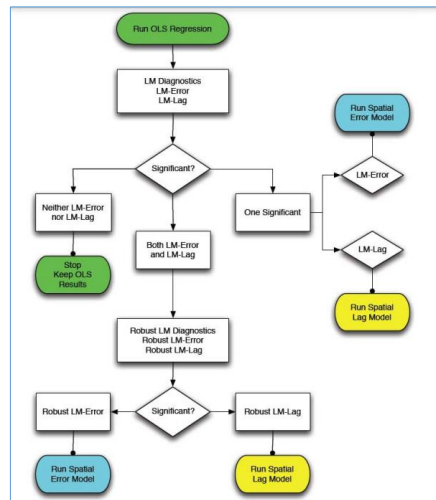
- Les résidus ε dans une unité spatiale peuvent avoir un impact sur les résidus dans une unité spatiale voisine.
 λ : paramètre représentant l'intensité de l'autocorrélation spatiale entre les résidus de la régression

A la différence du modèle précédent (SAR), on ne spécifie pas de relation particulière. La spatialisation est vu comme un « bruit » que l'on doit corriger : $y = X\beta + (I - \lambda W)^{-1} u$

- La détection de l'autocorrélation spatiale des erreurs : problème dans la spécification du modèle, telle que l'omission de variables significatives

Choix entre les modèles LM-Error (SEM) et les modèles LM-Lag (SAR) :

Approche « ascendante » (Le Gallo, 2002)



Si les deux sont significatifs, prendre celui qui a la p-value la plus faible

Si les deux Robust LM tests ne sont pas significatifs alors que les 2 LM Diagnostics le sont :

* Test Robust LM-Lag non significatif : l'hypothèse de la dépendance spatiale dans la variable dépendante n'est pas robuste après contrôle de l'autocorrélation spatiale des termes d'erreur.

* Test Robust LM-Error non significatif : l'hypothèse de l'autocorrélation spatiale dans les résidus n'est pas robuste après contrôle de la dépendance spatiale dans la variable dépendante

➔ Étant donné que les 2 Robust LM tests ne sont pas significatifs, cela implique qu'il n'y a pas de preuve solide en faveur d'un processus de retard spatial ou d'erreur spatiale exclusivement.

Solutions :

- Changer la spécification du modèle : variable omise ? Forme fonctionnelle à revoir
- Envisager d'autres types de modèles spatiaux : SDM, SLX

Attention : la lecture des effets dans le cas du modèle SAR n'est pas directe : il existe 2 types d'effets

$$\begin{aligned} Y &= (1 - \rho W)^{-1} X\beta + (1 - \rho W)^{-1} \varepsilon \\ &= \sum_{r=1}^k (1 - \rho W)^{-1} \beta_r X_r + (1 - \rho W)^{-1} \varepsilon \end{aligned}$$

La valeur prédite est donc : $\hat{y} = (1 - \hat{\rho}W)^{-1} X\hat{\beta}$

Cette valeur prédite est donc différente de $X\hat{\beta}$ (MCO)

L'effet marginal pour une variable quantitative n'est plus β_r mais $(1 - \rho W)^{-1} \beta_r$

- Termes diagonaux de $(1 - \rho W)^{-1} \beta_r$: effets directs pour chaque zone d'une modification de la variable X_r dans la même zone.
- Autres termes de $(1 - \rho W)^{-1} \beta_r$: effets indirects : impact de la modification de la variable X_r dans une zone sur une autre zone.

On peut donc calculer :

- Un effet direct moyen : moyenne des effets sur une zone d'une modification d'une unité de la variable X_r

- Un effet indirect moyen : moyenne des effets d'une modification d'une unité de la variable X_r dans une zone sur l'ensemble des zones
- Un effet total moyen = effet direct moyen + effet indirect moyen

Application sous R :

FVPTHH02 : Infractions contre les familles et les enfants (violence domestique) pour 1 000 ménages

Fonction de :

UNEMPP : % de chômeurs

SALESPC : Vente par habitant par an d'alcool, \$

Estimation du modèle MCO

```
mco<-lm(FVPTHH02~UNEMPP+SALESPC, data=carte)
summary(mco)
```

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	1.167254	0.404012	2.889	0.00423 **
UNEMPP	0.121642	0.065226	1.865	0.06346 .
SALESPC	-0.002540	0.004064	-0.625	0.53259

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.947 on 231 degrees of freedom

Multiple R-squared: 0.01483, Adjusted R-squared: 0.006304

F-statistic: 1.739 on 2 and 231 DF, p-value: 0.178

Autocorrélation spatiale des résidus du MCO : H0 : absence d'autocorrélation spatiale des résidus

$$I = \frac{\hat{\varepsilon}'W\hat{\varepsilon}}{\hat{\varepsilon}'\hat{\varepsilon}}$$

$$E(I) = \text{tr}(MW) / (N - K)$$

$$M = I - X(X'X)^{-1}X'$$

$$Z = \frac{I - E(I)}{\sqrt{\text{Var}(I)}} \sim N(0,1)$$

$$\text{Var}(I) = \frac{\text{tr}(MWMW) + \text{tr}(MWMW)^2 + [\text{tr}(MW)]^2}{(N - K)(N - K + 2)} - (E(I))^2$$

Si p-value < 0,05 → H₀ refusé

```
moran.lm<-lm.morantest(mco, WQueen, alternative="two.sided")
print(moran.lm)
```

Global Moran I for regression residuals

data:

model: lm(formula = FVPTHH02 ~ UNEMPP + SALESPC, data = carte)

weights: WQueen

Moran I statistic standard deviate = 4.2134, p-value = 2.515e-05

alternative hypothesis: two.sided

sample estimates:

Observed Moran I	Expectation	Variance
0.187391543	-0.004816203	0.002081008

→ Au seuil de risque de 1%, les résidus sont corrélés spatialement (selon la matrice de poids choisie) → MCO non adapté

```
LM<-lm.LMtests(mco, WQueen, test=c("LMerr", "LMlag", "RLMerr",
"RLMlag"))
print(LM)
```

les deux derniers sont les versions robustes

Rao's score (a.k.a Lagrange multiplier) diagnostics for spatial dependence

model: `lm(formula = FVPTHH02 ~ UNEMPP + SALESPC, data = carte)`

test weights: listw

RSerr = 16.492, df = 1, p-value = 4.885e-05

Rao's score (a.k.a Lagrange multiplier) diagnostics for spatial dependence

model: `lm(formula = FVPTHH02 ~ UNEMPP + SALESPC, data = carte)`

test weights: listw

RSlag = 18.773, df = 1, p-value = 1.473e-05

Rao's score (a.k.a Lagrange multiplier) diagnostics for spatial dependence

model: `lm(formula = FVPTHH02 ~ UNEMPP + SALESPC, data = carte)`

test weights: listw

adjRSerr = 10.307, df = 1, p-value = 0.001325

Rao's score (a.k.a Lagrange multiplier) diagnostics for spatial dependence

model: `lm(formula = FVPTHH02 ~ UNEMPP + SALESPC, data = carte)`

test weights: listw

adjRSlag = 12.587, df = 1, p-value = 0.0003884

library(spatialreg)

sar<-lagsarlm(FVPTHH02~UNEMPP+SALESPC, data=carte, WQueen)

summary(sar)

Type: lag

Coefficients: (asymptotic standard errors)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	0.6946964	0.4019265	1.7284	0.08391
UNEMPP	0.0934239	0.0618525	1.5104	0.13093
SALESPC	-0.0014521	0.0038529	-0.3769	0.70625

Rho: 0.32803, LR test value: 16.189, p-value: 5.7325e-05

positif et significatif: impact des voisins

Asymptotic standard error: 0.079746

z-value: 4.1135, p-value: 3.8979e-05

Wald statistic: 16.92, p-value: 3.8979e-05

Log likelihood: -575.3167 for lag model

ML residual variance (sigma squared): 7.8026, (sigma: 2.7933)

Number of observations: 234

Number of parameters estimated: 5

AIC: 1160.6, (AIC for lm: 1174.8)

LM test for residual autocorrelation il y a problème d'auto spatiale dans les résidus donc il faut tester d'autres modèles car on peut pas utiliser le Sem?

test value: 6.5777, p-value: 0.010326

impacts.sar<-impacts(sar, listw=WQueen)
impacts.sar

imaginons qu'on avait eu 0.11 au test précédent, on devrait calculer ce modèle

Impact measures (lag, exact):

	Direct	Indirect	Total
UNEMPP	0.095887905	0.0431424129	0.139030318
SALESPC	-0.001490429	-0.0006705822	-0.002161012

sem<-errorsarlm(FVPTHH02~UNEMPP+SALESPC, data=carte, WQueen)
summary(sem)

Type error

Coefficients: (asymptotic standard errors)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	1.3498805	0.4443509	3.0379	0.002383
UNEMPP	0.0698486	0.0638664	1.0937	0.274101
SALESPC	-0.0015187	0.0038553	-0.3939	0.693639

Lambda: 0.32528, LR test value: 15.077, p-value: 0.0001032
Asymptotic standard error: 0.0801
z-value: 4.0609, p-value: 4.8874e-05
Wald statistic: 16.491, p-value: 4.8874e-05

Log likelihood: -575.8726 for error model
ML residual variance (sigma squared): 7.8432, (sigma: 2.8006)
Number of observations: 234
Number of parameters estimated: 5
AIC: 1161.7, (AIC for lm: 1174.8)

Application sur Géoda :

Cliquer sur Regression, sélectionner la variable à expliquer ainsi que les variables explicatives

Sélectionner Classic

Cliquer sur Run

pas appliquer dans le dossier

SUMMARY OF OUTPUT: ORDINARY LEAST SQUARES ESTIMATION

Data set : NCVACO Variables
 Dependent Variable : FVPTH02 Number of Observations: 234
 Mean dependent var : 1.64369 Number of Variables : 3
 S.D. dependent var : 2.94982 Degrees of Freedom : 231

R-squared : 0.014834 F-statistic : 1.73907
 Adjusted R-squared : 0.006304 Prob(F-statistic) : 0.177976
 Sum squared residual: 2005.93 Log likelihood : -583.411
 Sigma-square : 8.68369 Akaike info criterion : 1172.82
 S.E. of regression : 2.94691 Schwarz criterion : 1189.19
 Sigma-square ML : 8.57236
 S.E. of regression ML: 2.92786

Variable	Coefficient	Std. Error	t-Statistic	Probability
CONSTANT	1.16725	0.404012	2.88916	0.00423
UNEMP	0.121642	0.0652287	1.86494	0.06346
SALESPC	-0.00254001	0.00406404	-0.624996	0.53259

REGRESSION DIAGNOSTICS

MULTICOLLINEARITY CONDITION NUMBER 4.316351

TEST ON NORMALITY OF ERRORS

TEST	DF	VALUE	PROB
Jarque-Bera	2	1752.3606	0.00000

DIAGNOSTICS FOR HETEROSKEDASTICITY

RANDOM COEFFICIENTS

TEST	DF	VALUE	PROB
Breusch-Pagan test	2	10.6140	0.00521
Koenker-Bassett test	2	1.5147	0.46890

Regression, sélectionner la variable à expliquer ainsi que les variables explicatives

Cliquer sur Weights File

Sélectionner Wqueen

Cliquer sur Spatial Lag

Cliquer sur Run

SUMMARY OF OUTPUT: SPATIAL LAG MODEL - MAXIMUM LIKELIHOOD ESTIMATION

Data set : NCVACO Variables
 Spatial Weight : WQueen
 Dependent Variable : FVPTH02 Number of Observations: 234
 Mean dependent var : 1.64369 Number of Variables : 4
 S.D. dependent var : 2.94982 Degrees of Freedom : 230
 Lag coeff. (Rho) : 0.328032

R-squared : 0.103302 Log likelihood : -575.317
 Sq. Correlation : - Akaike info criterion : 1150.63
 Sigma-square : 7.80256 Schwarz criterion : 1172.45
 S.E. of regression : 2.79331

Variable	Coefficient	Std. Error	z-value	Probability
W_FVPTH02	0.328032	0.0797462	4.11345	0.00004
CONSTANT	0.694696	0.401926	1.72842	0.08391
UNEMP	0.0934239	0.0618525	1.51043	0.13093
SALESPC	-0.00145213	0.00385285	-0.376997	0.70625

REGRESSION DIAGNOSTICS

DIAGNOSTICS FOR HETEROSKEDASTICITY

RANDOM COEFFICIENTS

TEST	DF	VALUE	PROB
Breusch-Pagan test	2	5.7778	0.05564

DIAGNOSTICS FOR SPATIAL DEPENDENCE

SPATIAL LAG DEPENDENCE FOR WEIGHT MATRIX : WQueen

TEST	DF	VALUE	PROB
Likelihood Ratio Test	1	16.1890	0.00006

Regression, sélectionner la variable à expliquer ainsi que les variables explicatives

Cliquer sur Weights File

Sélectionner Wqueen

Cliquer sur Spatial Error

Cliquer sur Run

SUMMARY OF OUTPUT: SPATIAL ERROR MODEL - MAXIMUM LIKELIHOOD ESTIMATION
 Data set : NCVACO Variables
 Spatial Weight : WQueen
 Dependent Variable : FVPTH02 Number of Observations : 234
 Mean dependent var : 1.643699 Number of Variables : 3
 S.D. dependent var : 2.949819 Degrees of Freedom : 231
 Lag coeff. (Lambda) : 0.325284

R-squared : 0.098635 R-squared (BUSE) : -
 Sq. Correlation : - Log likelihood : -575.872550
 Sigma-square : 7.84317 Akaike info criterion : 1157.75
 S.E of regression : 2.80057 Schwarz criterion : 1169.11

Variable	Coefficient	Std. Error	z-value	Probability
CONSTANT	1.34988	0.444351	3.03787	0.00238
UNEMP	0.0698486	0.0638664	1.09367	0.27410
SALESPC	-0.00151868	0.0038553	-0.39321	0.69364
LAMBDA	0.325284	0.0801005	4.06095	0.00005

REGRESSION DIAGNOSTICS

DIAGNOSTICS FOR HETEROSKEDASTICITY

RANDOM COEFFICIENTS

TEST

Breusch-Pagan test DF 2 VALUE 3.7522 PROB 0.15318

DIAGNOSTICS FOR SPATIAL DEPENDENCE

SPATIAL ERROR DEPENDENCE FOR WEIGHT MATRIX : WQueen

TEST

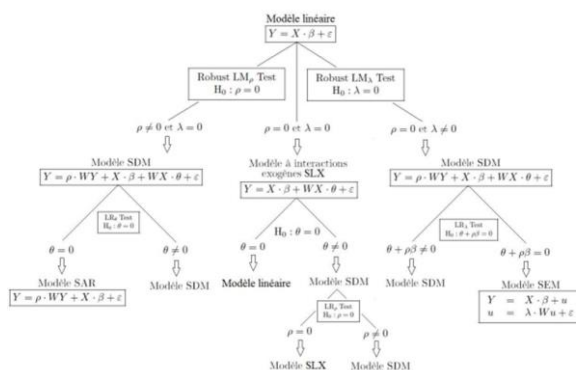
Likelihood Ratio Test DF 1 VALUE 15.0773 PROB 0.00010

Il existe d'autres types de modèles :

$y = \rho W y + X \beta + W X \theta + \varepsilon$ Spatial Durbin Model : SDM

$y = X \cdot \beta + W X \cdot \theta + \varepsilon$: Spatial Lag of X model : SLX

➔ Méthode de sélection : Approche « mixte » : Elhorst (2010)



Etape 1 :

→ Estimation par MCO

Etape 2 :

Tests de Lagrange (RLMerr, RLMlag)

- Si non significatifs → Estimation du modèle SLX : $y = X \cdot \beta + WX \cdot \theta + \varepsilon$
Si $\theta=0$, on estime alors un modèle MCO

Etape 3 :

Si $\theta \neq 0$, on estime alors un modèle SDM et on le compare à un modèle SLX

Par conséquent, on teste

$H_0 : \rho = 0$ (modèle SLX)

$H_1 : \rho \neq 0$ (modèle SDM)

$$LRstat = -2(LL_{SLX} - LL_{SDM}) \sim \chi^2(1)$$

Si $LRstat >$ valeur théorique → On retient le modèle SDM sinon on choisit le modèle SLX

Etape 2 :

Tests de Lagrange (RLMerr, RLMlag)

- Si un des 2 (ou les 2 sont) significatifs → Estimation du modèle SDM

Etape 3 :

On teste tout d'abord

$H_0 : \theta = 0$ (modèle SAR)

$H_1 : \theta \neq 0$ (modèle SDM)

$$LRstat = -2(LL_{SAR} - LL_{SDM}) \sim \chi^2(1)$$

Si $LRstat >$ valeur théorique → On retient le modèle SDM sinon on choisit le modèle SAR

On teste ensuite :

$H_0 : \theta + \rho\beta = 0$ (modèle SEM)

$H_1 : \theta + \rho\beta \neq 0$ (modèle SDM)

$$LRstat = -2(LL_{SEM} - LL_{SDM}) \sim \chi^2(1)$$

Si $LRstat >$ valeur théorique → On retient le modèle SDM sinon on choisit le modèle SEM

Remarque :

Si on choisit le modèle SLX, l'effet d'une variable X_r est β_r . L'effet indirect est θ_r

Si on choisit le modèle SDM, du fait de la présence de variable décalée, l'effet marginal d'une variable X_r est : $(I - \rho W)^{-1}(I_n \beta_r + W \theta_r)$

→ Il faut calculer des effets directs et indirects du même type que pour le modèle SAR

Application sous R :

#SLX non nécessaire ici puisque à l'étape 2, les tests sont significatifs
`slx<-lmSLX(FVPTH02~UNEMPP+SALESPC, data=carte, WQueen)`
`AIC(slx)`
`impacts(slx, listw=WQueen)`

#estimation d'un modèle SDM
`sdm<-lagsarlm(FVPTH02~UNEMPP+SALESPC, data=carte, WQueen, type="mixed")`

19 Econométrie spatiale – M.TRAVERS – Année 2024-2025

summary(sdm)

Type: mixed

Coefficients: (asymptotic standard errors)

	Estimate	Std. Error	z value	Pr(> z)
(Intercept)	-1.52011616	0.83529137	-1.8199	0.068780
UNEMPP	0.05232352	0.06346151	0.8245	0.409660
SALESPC	0.00069946	0.00386369	0.1810	0.856340
lag.UNEMPP	0.42110905	0.13674529	3.0795	0.002073
lag.SALESPC	0.00652359	0.00876196	0.7445	0.456553

le chômage des voisins (lag) a un impact sur le taux de violence du comté mais pas le chômage du comté même

Rho: 0.24765, LR test value: 8.4384, p-value: 0.0036738

Asymptotic standard error: 0.082887 le rho est significatif

z-value: 2.9878, p-value: 0.00281

Wald statistic: 8.9269, p-value: 0.00281

$$y = \rho W y + X \beta + W X \theta + \varepsilon$$

FVPTH02

Log likelihood: -570.2191 for mixed model

ML residual variance (sigma squared): 7.5532, (sigma: 2.7483)

Number of observations: 234

Number of parameters estimated: 7

AIC: 1154.4, (AIC for lm: 1160.9)

LM test for residual autocorrelation

test value: 2.7638, p-value: 0.096422

au-dessus de 0.05, pas d'erreur au niveau des résidus et on peut garder ce modèle.

20 Econométrie spatiale – M.TRAVERS – Année 2024-2025



Etape 3 : Test du rapport de vraisemblance

#SDM : Modèle non contraint

#SEM : Modèle contraint

TestSDM_SEM<-LR.Sarlm(sdm,sem)

print(TestSDM_SEM)

Likelihood ratio for spatial linear models

Likelihood ratio = 11.307, df = 2, p-value = 0.003506

sample estimates:

Log likelihood of sdm Log likelihood of sem

-570.2191 -575.8726

#SDM: Modèle non contraint

#SAR : Modèle contraint

TestSDM_SAR<-LR.Sarlm(sdm,sar)

print(TestSDM_SAR)

Likelihood ratio for spatial linear models

Likelihood ratio = 10.195, df = 2, p-value = 0.006112

sample estimates:

Log likelihood of sdm Log likelihood of sar

-570.2191 -575.3167

→ Il existe une différence significative entre SDM et SEM. On choisit le modèle ayant l'AIC le plus faible : SDM (1154 versus 1162)

→ Il existe une différence significative entre SDM et SAR. On choisit le modèle ayant l'AIC le plus faible : SDM (1154 versus 1161)

impacts.sdm<-impacts(sdm, listw=WQueen)
impacts.sdm

Impact measures (mixed, exact):

	<i>Direct</i>	<i>Indirect</i>	<i>Total</i>
UNEMPP	0.077468875	0.551801621	0.629270496
SALESPC	0.001087406	0.008513227	0.009600633

→ Faire le TD3 (cf. Madoc)